

# **Laboratorio de Datos**

## **Preprocesamiento: escalamiento y variables categóricas**

Primer Cuatrimestre 2026

Turno noche

Facultad de Ciencias Exactas y Naturales, UBA

# Preprocesamiento

En muchos casos, necesitamos realizar algunas transformaciones previas en los datos antes de ajustar un modelo de regresión (o cualquier modelo cuantitativo). Estas transformaciones pueden ser:

- 1 Normalizar variables numéricas, escalándolas para que los valores caigan en el intervalo  $[0,1]$
- 2 Normalizar variables numéricas llevándolas a media 0 y varianza 1.
- 3 Transformar variables categóricas binarias a 0-1.
- 4 Transformar variables categóricas con varias categorías.

# Ejemplo: infecciones en hospitales

| Variable Number | Variable Name                     | Description                                                                                                                                               |
|-----------------|-----------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1               | Identification number             | 1-113                                                                                                                                                     |
| 2               | Length of stay                    | Average length of stay of all patients in hospital (in days)                                                                                              |
| 3               | Age                               | Average age of patients (in years)                                                                                                                        |
| 4               | Infection risk                    | Average estimated probability of acquiring infection in hospital (in percent)                                                                             |
| 5               | Routine culturing ratio           | Ratio of number of cultures performed to number of patients without signs or symptoms of hospital-acquired infection, times 100                           |
| 6               | Routine chest X-ray ratio         | Ratio of number of X-rays performed to number of patients without signs or symptoms of pneumonia, times 100                                               |
| 7               | Number of beds                    | Average number of beds in hospital during study period                                                                                                    |
| 8               | Medical school affiliation        | 1 = Yes, 2 = No                                                                                                                                           |
| 9               | Region                            | Geographic region, where: 1 = NE, 2 = NC, 3 = S, 4 = W                                                                                                    |
| 10              | Average daily census              | Average number of patients in hospital per day during study period                                                                                        |
| 11              | Number of nurses                  | Average number of full-time equivalent registered and licensed practical nurses during study period (number full time plus one half the number part time) |
| 12              | Available facilities and services | Percent of 35 potential facilities and services that are provided by the hospital                                                                         |

Reference: Special Issue, "The SENIC Project," *American Journal of Epidemiology* 111 (1980), pp. 465-653. Data obtained from Robert W. Haley, M.D., Hospital Infections Program, Center for Infectious Diseases, Centers for Disease Control, Atlanta, Georgia 30333.

# Escalamiento min-max

Este escalamiento es una transformación lineal. Es decir, se aplica una fórmula de la forma

$$x_{\text{nuevo}} = a \cdot x + b$$

Los valores de  $a$  y  $b$  se eligen de forma que los valores de la variable transformada se encuentren en el intervalo  $[0,1]$ .

# Escalamiento min-max

Este escalamiento es una transformación lineal. Es decir, se aplica una fórmula de la forma

$$x_{\text{nuevo}} = a \cdot x + b$$

Los valores de  $a$  y  $b$  se eligen de forma que los valores de la variable transformada se encuentren en el intervalo  $[0,1]$ .

La fórmula que debemos aplicar es

$$x_{\text{nuevo}} = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

El escalamiento MinMax lleva a que todas las variables tengan una dispersión similar y por lo tanto podamos comparar el peso de cada variable en el modelo mirando los coeficientes.

# Escalamiento min-max

¿Cuáles pueden ser las ventajas de este escalamiento, comparado con solamente dividir con el máximo?

# Escalamiento min-max

¿Cuáles pueden ser las ventajas de este escalamiento, comparado con solamente dividir con el máximo?

**Ejemplo.** Si una variable tiene todos valores entre 390 y 400, si solo dividimos por el máximo quedarán valores entre 0.975 y 1.

Para que esas pequeñas diferencias impacten en el modelo, necesitaremos multiplicar la variable por un coeficiente alto.

# Escalamiento min-max

Supongamos que

- $x_1$  tiene valores en el intervalo  $[0, 1]$
- $x_2$  tiene valores en el intervalo  $[0.975, 1]$

En un modelo

$$y = 4x_1 + 4x_2$$

la variable  $x_1$  tiene más peso. Las observaciones con puntaje alto van a ser las que tengan un valor de  $x_1$  alto, las variaciones en  $x_2$  van a tener un aporte muy menor.



**Otro ejemplo:** En muchos concursos docentes, la prueba de oposición tiene un puntaje alto (50 o 70 puntos sobre 100), y por lo tanto a priori es la parte más importante del concurso.

Sin embargo en muchos concursos los valores son similares, la mayoría de los concursantes obtiene notas entre 60 y 70. Por lo tanto el peso de la prueba de oposición en el concurso termina siendo mucho menor.

# Escalamiento min-max

**Pregunta:** ¿En qué situación este escalamiento podría resultar inadecuado?

**Pregunta:** ¿En qué situación este escalamiento podría resultar inadecuado?

Este escalamiento se ve muy influenciado por la presencia de outliers.

Si tenemos outliers en una variable, llevaremos el outlier a 1, y los demás valores a valores muy pequeños.

## 2. Escalamiento estándar

Otro escalamiento muy común es llevar las variables a media 0 y varianza 1.

## 2. Escalamiento estándar

Otro escalamiento muy común es llevar las variables a media 0 y varianza 1.

Para eso aplicamos la fórmula:

$$\tilde{x} = \frac{x - \bar{x}}{\sigma},$$

donde  $\bar{x}$  es la media y  $\sigma$  es el desvío estándar.

# Escalamiento estándar

Las principales ventajas son:

- ① Menor sensibilidad que min-max (aunque no inmune) a outliers.
- ② No se descalibra si agregamos nuevos valores fuera de rango.

Posibles ventajas de min-max:

- ① Es más simple.
- ② No introduce valores negativos (que pueden traer problemas si aplicamos logaritmos u otras funciones).
- ③ En algunos casos, los valores de una variable se mueven en un rango prefijado y solo queremos ajustar el rango, por ejemplo llevar variables 0-100 a variables 0-1.

# Codificación de Variables Binarias

- Variables con dos valores posibles, por ejemplo: sí/no, verdadero/falso.
- Codificación habitual:
  - $\text{sí} \rightarrow 1$
  - $\text{no} \rightarrow 0$
- Ejemplo:

| Respuesta | Codificada |
|-----------|------------|
| Sí        | 1          |
| No        | 0          |
| Sí        | 1          |

# Codificación de Variables Categóricas

- Variables con más de dos categorías, por ejemplo: rojo, verde, azul.
- Codificación mediante **dummies** (variables indicadoras):
  - Una columna por cada categoría (o  $k - 1$  para evitar multicolinealidad).
- Ejemplo:

| Cliente   | Color de auto | Rojo | Verde | Azul |
|-----------|---------------|------|-------|------|
| Juan      | Rojo          | 1    | 0     | 0    |
| Margarita | Verde         | 0    | 1     | 0    |
| Ana       | Azul          | 0    | 0     | 1    |
| Pedro     | Rojo          | 1    | 0     | 0    |

La última columna es redundante, se puede deducir de las anteriores. Si el modelo tiene intercept, habría dependencia lineal entre las variables y por lo tanto es conveniente eliminar esa columna.



# Información redundante y dependencia lineal entre variables

- **Concepto intuitivo:** queremos evitar información redundante (si tenemos una variable que nos indica si alguien fuma, no necesitamos otra que nos diga si alguien NO fuma)
- **Traducción matemática en modelos lineales:** queremos evitar dependencia lineal entre variables (si una variable es combinación lineal de otras, no aporta nada al modelo)
- **Ojo:** Si queremos usar una variable  $x$  y su cuadrado  $x^2$ , puede ser redundante guardar ambas variables en la base de datos, pero no son linealmente dependientes, tenemos que ingresar las dos en un modelo lineal.

## $k$ dummies o $k - 1$ ?

- En modelos lineales, lo más común es tener un intercept.
- En ese caso, para cada variable categórica, si tiene  $k$  categorías, agregamos dummies para  $k - 1$  categorías, para evitar colinealidad.
- La categoría que no usamos la llamamos base o referencia.

## $k$ dummies o $k - 1$ ?

Cuando hay intercept, usamos  $k - 1$  dummies para cada variable con  $k$  categorías

### Hay colinealidad

| Int. | Sí | No |
|------|----|----|
| 1    | 1  | 0  |
| 1    | 0  | 1  |
| 1    | 1  | 0  |
| 1    | 0  | 1  |

Intercept = Sí + No

### No hay colinealidad

| Int. | Sí |
|------|----|
| 1    | 1  |
| 1    | 0  |
| 1    | 1  |
| 1    | 0  |

La categoría “No”  
queda representada  
cuando la dummy  
vale 0.

### Dos variables categóricas No hay colinealidad

| Int. | Fuma | R. medio | R. alto |
|------|------|----------|---------|
| 1    | 1    | 0        | 0       |
| 1    | 0    | 1        | 0       |
| 1    | 1    | 0        | 1       |
| 1    | 0    | 0        | 0       |

Las categorías base son:  
“No fumador” y “Riesgo bajo”.

## $k$ dummies o $k - 1$ ?

Cuando **no** hay intercept, usamos  $k$  dummies para una variable categórica y  $k - 1$  para todas las demás.

### Sin intercept

| Sí | No |
|----|----|
| 1  | 0  |
| 0  | 1  |
| 1  | 0  |
| 0  | 1  |

No hay colinealidad.

### Sin intercept, $k$ dummies para c/ variable

| Fuma | No Fuma | R. alto | R. medio | R. bajo |
|------|---------|---------|----------|---------|
| 1    | 0       | 0       | 0        | 1       |
| 0    | 1       | 0       | 1        | 0       |
| 1    | 0       | 1       | 0        | 0       |
| 1    | 0       | 0       | 1        | 0       |

Hay colinealidad. Debemos eliminar una variable.

**Regla práctica:** usar intercept y  $k - 1$  categorías para cada variable categórica, pero es importante estar atento a cómo usamos las variables en el modelo.