

Correlación y R^2

Laboratorio de Datos, IC - FCEN - UBA - 1er. Cuatrimestre 2026

13 de mayo de 2026

Para calcular los parámetros de un modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

buscamos los β que minimicen la suma de los cuadrados de los residuos:

$$RSS(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$

donde y_i son los datos reales y $\hat{y}_i$ las estimaciones (o predicciones) del modelo.

Para calcular los parámetros de un modelo

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

buscamos los β que minimicen la suma de los cuadrados de los residuos:

$$RSS(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2,$$


donde y_i son los datos reales y $\hat{y}_i$ las estimaciones (o predicciones) del modelo.

Las medidas de desempeño del modelo son análogas a las de Regresión Lineal univariada:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$ECM = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Porcentaje de varianza explicada




- Variabilidad total (TSS) = $\sum_{i=1}^n (y_i - \bar{y})^2$
- Variabilidad explicada (ESS) = $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
- Variabilidad no explicada (RSS) = $\sum_{i=1}^n (y_i - \hat{y}_i)^2$

En regresión lineal con intercept (tanto univariada como multivariada), vale:

$$\text{var. total}(TSS) = \text{var. explicada}(ESS) + \text{var. no explicada}(RSS)$$

Porcentaje de varianza explicada



$$R^2 = 1 - \frac{\text{variabilidad no explicada}}{\text{variabilidad total}}$$

Vale:

$$\text{var. total}(TSS) = \text{var. explicada}(ESS) + \text{var. no explicada}(RSS)$$

Obtenemos la expresión equivalente

$$R^2 = \frac{\text{variabilidad explicada}}{\text{variabilidad total}} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

Es decir, podemos interpretar a R^2 como el **porcentaje de varianza explicada**.

Varianza. Ya vimos la fórmula de varianza para una variable $x = (x_1, x_2, \dots, x_n)$:

$$\text{var}(x) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n},$$

donde $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$ es el promedio o la media de los valores de x .
Recordemos la definición de producto interno entre vectores:

$$\langle x, y \rangle = x_1 y_1 + x_2 y_2 + \dots + x_n y_n = \begin{pmatrix} x_1 & x_2 & \dots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = x^T y.$$

Usando productos internos podemos escribir

$$\text{var}(x) = \frac{\langle x - \bar{x}, x - \bar{x} \rangle}{n} = \frac{\|x - \bar{x}\|^2}{n}.$$

Covarianza. Definimos ahora la covarianza entre dos variables $x = (x_1, x_2, \dots, x_n)$ e $y = (y_1, y_2, \dots, y_n)$ que mide la relación entre ellas:

$$\text{cov}(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n} = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{n}$$

Interpretación:

- Si $(y_i - \bar{y})$ es siempre positivo cuando $(x_i - \bar{x})$ es positivo, la covarianza será grande positiva.
- Si uno es siempre positivo cuando el otro es negativo, la covarianza será grande negativa.
- Si no hay relación, los términos positivos se cancelan con los negativos y la covarianza es 0.

Correlación. Dividiendo la fórmula de covarianza por los desvíos de cada variable obtenemos la fórmula de correlación:

$$\text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)}\sqrt{\text{var}(y)}} = \frac{\text{cov}(x, y)}{\sigma(x)\sigma(y)}$$

(estamos *normalizando* la covarianza)

Podemos reescribir esta fórmula:


$$\text{corr}(x, y) = \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}}{\frac{\|x - \bar{x}\|}{\sqrt{n}} \frac{\|y - \bar{y}\|}{\sqrt{n}}} = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|},$$

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$


La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es



Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$




La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° ,

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$




La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° , la correlación es 1.
- Si el ángulo es 180° ,

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$




La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° , la correlación es 1.
- Si el ángulo es 180° , la correlación es -1.
- Si el ángulo es 90° ,

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:


$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$





La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° , la correlación es 1.
- Si el ángulo es 180° , la correlación es -1.
- Si el ángulo es 90° , la correlación es 0.

Correlación - Ejemplos




Correlación - Ejemplos




Correlación: ≈ 1


Correlación - Ejemplos




Correlación: ≈ 1




Correlación: ≈ -1




Correlación - Ejemplos



Correlación: ≈ 1




Correlación: ≈ -1





Correlación: 0

Correlación - Ejemplos




Correlación - Ejemplos




Correlación: 0

Correlación - Ejemplos



Correlación: 0



Correlación: 0

Regresión lineal simple: R^2 y correlación

Consideremos el modelo de regresión lineal simple

$$y_i \sim \beta_0 + \beta_1 x_i + \varepsilon_i.$$

En este caso, el **coeficiente de determinación** puede escribirse como

$$R^2(y | x) = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}.$$

Pero además ocurre una identidad especial¹:

$$R^2(y | x) = \text{corr}(x, y)^2.$$

Como $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$, vale

$$\text{corr}(x, y) = \text{corr}(y, x)$$

y por lo tanto

$$R^2(y | x) = R^2(x | y)$$

¹Si quieren pensar la demo como ejercicio, usen las fórmulas que dio Nazareno para β_0 y β_1 .

Qué pasa con `r2_score`?

Ojo! En Python, para regresión lineal simple

$$\text{r2_score}(y_true, y_pred) = R^2(y \mid x)$$

pero **NO** vale $R^2(x \mid y) = \text{r2_score}(y_pred, y_true)$.

La función `r2_score(y_true, y_pred)` no es simétrica, tenemos que darle primero el y verdadero y segundo las predicciones.

En una regresión con varios predictores (o regresión polinomial con un predictor):

$$y \sim \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + \varepsilon.$$

El coeficiente de determinación sigue siendo

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}},$$

pero ya no coincide con el cuadrado de una correlación ordinaria.

$$R^2(y \mid x_1, x_2, \dots, x_p) = \text{r2_score}(y_true, y_pred) \neq \text{r2_score}(y_pred, y_true).$$

(este último valor no corresponde a ningún modelo).