

Laboratorio de Datos

Interacciones entre variables

Primer Cuatrimestre 2026
Turno noche

Facultad de Ciencias Exactas y Naturales, UBA

Fórmulas de Wilkinson

Wilkinson y Rogers, dos señores ocupados en hacer cantidades de estudios de análisis de la varianza (ANOVA), deciden sentarse a elegir una *descripción simbólica* de los modelos:

Wilkinson, G. N., & Rogers, C. E. (1973). Symbolic Description of Factorial Models for Analysis of Variance. *Applied Statistics*, 22(3), 392

Fórmulas de Wilkinson


Wilkinson y Rogers, dos señores ocupados en hacer cantidades de estudios de análisis de la varianza (ANOVA), deciden sentarse a elegir una *descripción simbólica* de los modelos:

Wilkinson, G. N., & Rogers, C. E. (1973). Symbolic Description of Factorial Models for Analysis of Variance. *Applied Statistics*, 22(3), 392

Se hicieron populares con S (el antecesor de R) y a hoy, todo *software* de modelo lineal implementa su propia (ligera e insidiosamente diferente) *gramática de fórmulas*.

Formulaic: Wilkinson en Python, bien rápido

En R las fórmulas son objetos de primer nivel. En python, la librería patsy las implementa hace tiempo, y en statsmodels se usan ampliamente. En este curso consideraremos una implementación más reciente: formulaic.



Formulaic

[▶ Documentación](#)[▶ Gramática](#)

Formulaic en acción

```
import pandas as pd
from formulaic import model_matrix

df = pd.DataFrame({
    'y': [0, 1, 2],
    'a': ['A', 'B', 'C'],
    'b': [0.3, 0.1, 0.2],
})
y, X = model_matrix("y ~ a + b + a:b", df)
pd.concat([y, X], axis=1)
```

Formulaic en acción

```
import pandas as pd
from formulaic import model_matrix

df = pd.DataFrame({
    'y': [0, 1, 2],
    'a': ['A', 'B', 'C'],
    'b': [0.3, 0.1, 0.2],
})

y, X = model_matrix("y ~ a + b + a:b", df)
pd.concat([y, X], axis=1)
```

	y	Intercept	a[T.B]	a[T.C]	b	a[T.B]:b	a[T.C]:b
0	0	1.0	0	0	0.3	0.0	0.0
1	1	1.0	1	0	0.1	0.1	0.0
2	2	1.0	0	1	0.2	0.0	0.2

¿Gramática?

Claro! Hete aquí una breve descripción de los operadores más usuales:

Operador	Ejemplo	Función
$\sim$	$y \sim x$	Separar variable respuesta de los predictores
$+$	$y \sim x + z$	Adicionar términos al modelo
$:$	$y \sim x : z$	Interacción (producto) entre términos
$*$	$y \sim x * z$	Adición e interacción: equivale a $x + z + x : z$

Gramática (cont.)

Otros operadores:

- - para quitar términos: $y \sim x - 1$
- ^ o ** para interacciones hasta orden n

Gramática (cont.)

Otros operadores:

- $-$ para quitar términos: $y \sim x - 1$
- $\wedge$ o $**$ para interacciones hasta orden n

Transformaciones con `formulaic`:

- Funciones arbitrarias: $y \sim \text{mi_fun}(x)$
- Módulo numpy como `np`: $y \sim \text{np.log}(x)$
- Funciones propias como `center`

Gramática (cont.)

Otros operadores:

- $-$ para quitar términos: $y \sim x - 1$
- $\wedge$ o $**$ para interacciones hasta orden n

Transformaciones con `formulaic`:

- Funciones arbitrarias: $y \sim \text{mi_fun}(x)$
- Módulo numpy como `np`: $y \sim \text{np.log}(x)$
- Funciones propias como `center`

Uso de paréntesis para agrupar términos: $y \sim (a + b) : c$

¿Y el intercept?

Por omisión, los modelos incluyen un intercept. Se puede:

- Hacerlo explícito: $y \sim x + 1$
- Quitarlo: $y \sim x - 1$

¿Y el intercept?

Por omisión, los modelos incluyen un intercept. Se puede:

- Hacerlo explícito: $y \sim x + 1$
- Quitarlo: $y \sim x - 1$

En R también se usa $+ 0$ para remover la ordenada.

Un ejemplo con pingüinos

Supongamos que queremos estudiar la relación entre la masa corporal `masa` de los pingüinos registrados en el dataset `penguins`, su sexo, la isla de nacimiento y el largo de las aletas (`aleta_mm`).

Un ejemplo con pingüinos

Supongamos que queremos estudiar la relación entre la masa corporal `masa` de los pingüinos registrados en el dataset `penguins`, su sexo, la isla de nacimiento y el largo de las aletas (`aleta_mm`).

Asumiendo que la masa es proporcional al *volumen* del pingüino, puedo imaginar una relación $y \sim \text{poly}(\text{aleta_mm}, 3)$.

Un ejemplo con pingüinos

Supongamos que queremos estudiar la relación entre la masa corporal *masa* de los pingüinos registrados en el dataset `penguins`, su sexo, la isla de nacimiento y el largo de las aletas (`aleta_mm`).

Asumiendo que la masa es proporcional al *volumen* del pingüino, puedo imaginar una relación $y \sim \text{poly}(\text{aleta_mm}, 3)$.

Si creo que además el sexo del pingüino influye en la relación, puedo agregarlo como $y \sim \text{poly}(\text{aleta_mm}, 3) + \text{sexo}$. ¿Pero cómo cambiaría la masa en relación a una variable categórica?

¿Y si quiero que las rectas tengan distintas pendientes según el sexo?

Un ejemplo con pingüinos

Supongamos que queremos estudiar la relación entre la masa corporal `masa` de los pingüinos registrados en el dataset `penguins`, su sexo, la isla de nacimiento y el largo de las aletas (`aleta_mm`).

Un ejemplo con pingüinos

Supongamos que queremos estudiar la relación entre la masa corporal `masa` de los pingüinos registrados en el dataset `penguins`, su sexo, la isla de nacimiento y el largo de las aletas (`aleta_mm`).

Asumiendo que la masa es proporcional al *volumen* del pingüino, puedo imaginar una relación $y \sim \text{poly}(\text{aleta_mm}, 3)$.

Un ejemplo con pingüinos

Supongamos que queremos estudiar la relación entre la masa corporal *masa* de los pingüinos registrados en el dataset `penguins`, su sexo, la isla de nacimiento y el largo de las aletas (`aleta_mm`).

Asumiendo que la masa es proporcional al *volumen* del pingüino, puedo imaginar una relación $y \sim \text{poly}(\text{aleta_mm}, 3)$.

Si creo que además el sexo del pingüino influye en la relación, puedo agregarlo como $y \sim \text{poly}(\text{aleta_mm}, 3) + \text{sexo}$. ¿Pero cómo cambiaría la masa en relación a una variable categórica?

¿Y si quiero que las rectas tengan distintas pendientes según el sexo?

Variables categórica sumando en el modelo

Modelo 1: $\text{bill_depth_mm} \sim \text{bill_length_mm} + \text{species}$

La fórmula del modelo es

$$\text{bill_depth_mm} = \beta_0 + \beta_1 \text{bill_length_mm} + \beta_2 \text{species}[B] + \beta_3 \text{species}[C]$$

Si un pingüino es especie A, la fórmula queda

$$\text{bill_depth_mm} = \beta_0 + \beta_1 \cdot \text{bill_length_mm}$$

Si un pingüino es especie B, la fórmula queda

$$\text{bill_depth_mm} = \beta_0 + \beta_1 \cdot \text{bill_length_mm} + \beta_2$$

Si un pingüino es especie C, la fórmula queda

$$\text{bill_depth_mm} = \beta_0 + \beta_1 \cdot \text{bill_length_mm} + \beta_3$$

Variables categórica sumando en el modelo

Modelo 1: $\text{bill_depth_mm} \sim \text{bill_length_mm} + \text{species}$

Recordando que $y = \text{bill_depth_mm}$ y $x = \text{bill_length_mm}$, vemos que en los tres casos la pendiente de x es la misma, solo cambia la ordenada al origen.

Si un pingüino es especie A, la fórmula queda

$$\text{bill_depth_mm} = \beta_0 + \beta_1 \cdot \text{bill_length_mm}$$

Si un pingüino es especie B, la fórmula queda

$$\text{bill_depth_mm} = (\beta_0 + \beta_2) + \beta_1 \cdot \text{bill_length_mm}$$

Interacción con una variables categórica

Modelo 2: $y \sim x * z$

con z variable categórica de 2 categorías Sí y No. La fórmula del modelo es

$$y = \beta_0 + \beta_1 x + \beta_2 \cdot z[Si] + \beta_3 \cdot x \cdot z[Si]$$

(porque no hay otras combinaciones?)

Si un individuo es no-fumador, la fórmula queda

$$y = \beta_0 + \beta_1 x$$

Si un individuo es fumador, la fórmula queda

$$y = \beta_0 + \beta_1 x + \beta_2 + \beta_3 x$$

Vemos que se modifica tanto la ordenada al origen como la pendiente:

$$y = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)x$$

Paradoja de Simpson — ejemplo numérico

Casos leves

Tratamiento	Éxitos	Total	Tasa
A	19	20	95 %
B	80	100	80 %

Casos graves

Tratamiento	Éxitos	Total	Tasa
A	30	100	30 %
B	2	20	10 %

Paradoja de Simpson — ejemplo numérico

Casos leves

Tratamiento	Éxitos	Total	Tasa
A	19	20	95 %
B	80	100	80 %

Casos graves

Tratamiento	Éxitos	Total	Tasa
A	30	100	30 %
B	2	20	10 %

En ambos grupos: **A es mejor que B.**

Paradoja de Simpson — ejemplo numérico

Casos leves

Tratamiento	Éxitos	Total	Tasa
A	19	20	95 %
B	80	100	80 %

Casos graves

Tratamiento	Éxitos	Total	Tasa
A	30	100	30 %
B	2	20	10 %

En ambos grupos: **A es mejor que B.**

Total (sin separar por grupo)

Tratamiento	Éxitos	Total	Tasa
A	49	120	40.8 %
B	82	120	68.3 %

En el total: **A parece peor que B.**