

Introducción a SQL

Laboratorio de Datos, IC - FCEN - UBA

Primer Cuatrimestre 2026

20 de mayo de 2026

¿Por qué SQL en un curso de Ciencia de Datos?


- En la práctica, la mayoría de los proyectos de ciencia de datos no comienzan con archivos CSV (ni datasets en módulos Python).
- La mayor parte de los datos reales viven en **bases de datos**.
- SQL (Structured Query Language, ese-cu-ele o sequel) es el lenguaje estándar para **consultar datos estructurados**.
- SQL + Python
 - Usamos SQL para **definir y extraer conjuntos de datos**.
 - Usamos Python para **analizar, modelar y visualizar**.

Idea clave:

SQL = ¿qué datos queremos? Python = ¿qué hacemos con esos datos?

Breve reseña histórica

- En 1970, Edgar F. Codd propuso el **modelo relacional**.



Una relación con 5 atributos y 4 tuplas puede visualizarse como una tabla con 5 columnas y 4 filas. Sin embargo, a diferencia de las filas y columnas de una tabla, los atributos y las tuplas de una relación no tienen orden.

- Durante fines de los años 70 y los 80, surge SQL como un **lenguaje** para consultar bases de datos relacionales.
- Con el tiempo, SQL se convierte en el estándar dominante para trabajar con bases de datos relacionales.

El modelo relacional en Ciencia de Datos

- El modelo relacional organiza los datos en **tablas** (relaciones)
- En problemas reales, la información suele dividirse en múltiples tablas:
 - usuarios, eventos, transacciones, productos, sensores, ubicaciones, etc.
- Estas tablas pueden vincularse mediante **claves**.

Por ejemplo:

- **usuarios** (user_id, país, fecha_alta)
- **pedidos** (order_id, user_id, fecha, monto)

Cada pedido está asociado a un usuario a través de la clave user_id.

Bases de datos no-relacionales?

Ejemplo: MongoDB. En lugar de tablas y filas, se guardan documentos con formato:

```
{
  _id: ObjectId("682b7d9f8c2a4d1e5f9a1234"),
  titulo: "V Jornadas de investigación y difusión IC/IMAS",
  texto: "Tendrán lugar los días miércoles 7 y jueves 8 de mayo.",
  categoria: "Noticias",
  likes: 1,
  tags: ["difusion", "investigacion"],
  fecha: ISODate("2025-05-07T00:00:00Z"),
  comentarios: [
    {
      usuario: "Pedro",
      texto: "No me la pierdo!"
    }
  ]
}
```

Cómo se integra SQL en el flujo de trabajo en Ciencia de Datos

Base de datos $\longrightarrow$ Consulta SQL $\longrightarrow$ DataFrame $\longrightarrow$ Análisis

- SQL se utiliza principalmente para:
 - filtrar datos,
 - combinar tablas,
 - calcular agregados.
- Python se utiliza principalmente para:
 - visualización,
 - análisis estadístico,
 - modelado.