

Clase_Clustering

Dr. Federico Giovannetti

2026-02-22

Aprendizaje Supervisado y No Supervisado

Aprendizaje supervisado:

- ▶ El objetivo es predecir una variable respuesta a partir de variables explicativas.
- ▶ Conocemos la “respuesta correcta” para un conjunto de datos y usamos esos datos para construir el modelo.

Aprendizaje no supervisado


- ▶ El objetivo es encontrar patrones o estructuras latentes en los datos.
- ▶ A priori no hay (o no nos interesa) encontrar una “respuesta correcta”.

Clustering

Es una técnica de aprendizaje no supervisado.

Agrupar datos similares en conjuntos llamados clústeres.


Se puede usar para construir grupos, segmentar audiencias, análisis de redes sociales, buscar perfiles, etc.



Tipos de métodos de clustering

- ▶ De partición (partitioning)
- ▶ Jerárquicos
- ▶ Densidad
- ▶ Basados en modelos
- ▶ entre otros...

Tipos de métodos de clustering




Cada método tiene sus ventajas y desventajas. Acá vamos a ver los más simples y populares.

K-means

La forma más simple de pensar en la lógica del clustering es imaginarnos a cada observación de nuestros datos como un punto en un espacio de **n** dimensiones donde **n** es la cantidad de variables.

Es más fácil imaginarlo a partir de los datos de penguins. Usando dos variables, ¿Podríamos clasificar a los pingüinos a partir de la cercanía de los puntos en este espacio de 2 dimensiones?



K-means

Eso es exactamente lo que hacen las versiones más simples del algoritmo k-means: Particiona los datos en **k** clusters a partir de la definición de un número **k** de centroides


Cada cluster debería ser un conjunto de datos que se encuentra suficientemente cerca entre quienes pertenecen al mismo grupo, y suficientemente lejos de quienes pertenecen a los otros grupos.

En r, usamos la función **kmeans()**

K-means ¿Cómo funciona?

Para entender como funciona, podemos usar este simulador


Tenemos una serie de puntos claramente agrupados y queremos usar kmeans para que la compu los identifique



K-means ¿Cómo funciona?


Para entender como funciona, podemos usar este simulador

1. Establecemos una cantidad (k) de centros y los ubicamos al azar




K-means ¿Cómo funciona?

2. Asignamos cada punto a un cluster a partir del centro que tenga más cerca (usamos distancia euclídeana)




K-means ¿Cómo funciona?

3. Actualizamos la ubicación de los centros. Para esto, calculamos la media de los valores de los puntos pertenecientes a cada cluster.




K-means ¿Cómo funciona?

4. Volvemos a asignar los puntos a unos clusters a partir de su cercanía con los nuevos puntos



K-means ¿Cómo funciona?

5. Repetimos 3 y 4 hasta alcanzar **convergencia**. Es decir, hasta que la asignación de puntos no cambie.





K-means - Ventajas

- ▶ Simple y fácil de implementar.
- ▶ Escalable para grandes conjuntos de datos y util también para tamaños de muestra chicos.



Ejemplos

¿En cuál de estos casos, los clusters quedarán bien definidos a partir de sus centros?



Ejemplos



¿En cuál de estos casos, los clusters quedarán bien definidos a partir de sus centros?



Aplicaciones de k -means


¿En cuáles de estas aplicaciones el método de k -means puede resultar apropiado?

- 1 Clasificar especies animales según características (peso, largo, longitud de la cola, ...).
- 2 Identificar distintas componentes de una imagen.



K-means - Desventajas:


- ▶ Requiere especificar el número de clústeres de antemano.
- ▶ Sensible a la elección de los centroides iniciales.
- ▶ Puede converger a mínimos locales.
- ▶ Sensible a outliers
- ▶ Los clusters tienen que ser esféricos



Requerimientos para poder aplicar k -medias


k -medias supone las siguientes propiedades de los datos, y puede fallar si estas propiedades no se cumplen:

- 1 Los clusters son esféricos e isotrópicos (el mismo radio en todas las direcciones).
- 2 Los clusters tienen la misma varianza.
- 3 Todos los clusters tienen aproximadamente la misma cantidad de puntos.



K -medias como problema de optimización

Podemos plantear el problema de clustering por k -medias como un problema de optimización (y el algoritmo k -medias naive es un método simple de optimización).



- Buscamos minimizar la "suma de los errores".
- Consideramos que los errores son las distancias (al cuadrado) de cada punto al centro de su cluster: $\|\mathbf{x} - \boldsymbol{\mu}_i\|^2$.
- Es decir, queremos minimizar la suma de los cuadrados dentro de cada cluster (WCSS o within cluster sum of squares).
- Formalmente queremos elegir clusters $S_1, \dots, S_k$ y centros $\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_k$ que minimicen:

$$WCSS = \sum_{i=1}^k \sum_{\mathbf{x} \in S_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

¿Número óptimo de clusters?

- A medida que aumentamos la cantidad de clusters, el error WCSS disminuye.
- Por lo tanto no hay un número óptimo de clusters.
- Podemos mirar la curva y ver cuándo aumentar la cantidad de clusters no reduce significativamente el error WCSS.
- Este proceso suele llamarse “método del codo”.

